

LAPORAN PROJECT AKHIR MATA KULIAH DATA WRANGLING
Analisis Tren Angka Harapan Hidup Penduduk Indonesia Berdasarkan
Provinsi pada Rentan waktu 2010-2024



Dosen Pengampu Mata Kuliah:

Ulfa Siti Nuraini, S.Stat., M.Stat

Disusun Oleh:

- | | |
|---------------------------|-------------|
| 1. Fitri Saidatur Hanifah | 24031554035 |
| 2. Kafka Praya Firmansyah | 24031554182 |

Sains Data

Fakultas Matematika dan Ilmu Pengetahuan Alam

Universitas Negeri Surabaya

2025

BAB I

PENDAHULUAN

1.1 Latar Belakang

Angka Harapan Hidup (AHH) merupakan indikator penting yang menggambarkan kualitas kesehatan dan kesejahteraan masyarakat. Di Indonesia, perkembangan AHH menunjukkan variasi yang cukup signifikan antarprovinsi serta perbedaan yang konsisten antara laki-laki dan perempuan. Faktor-faktor seperti akses kesehatan, kondisi sosial ekonomi, dan karakteristik wilayah turut membentuk dinamika tersebut. Oleh karena itu, analisis tren AHH berbasis gender dan provinsi menjadi relevan untuk memahami kesenjangan yang masih terjadi serta mengidentifikasi daerah yang memerlukan perhatian khusus.

Dalam penelitian ini, data dari BPS, Provinsi Jawa Barat, dan Provinsi Aceh digunakan secara terintegrasi untuk menghasilkan gambaran AHH yang lebih lengkap. Ketiga sumber data tersebut saling melengkapi dari segi cakupan wilayah, kedalaman informasi, serta pemisahan berdasarkan jenis kelamin. Dengan menggabungkannya, analisis tren dapat dilakukan secara konsisten untuk melihat perubahan AHH dari tahun ke tahun sekaligus membandingkan perbedaan gender di seluruh provinsi Indonesia.

Penelitian “Analisis Tren Angka Harapan Hidup Penduduk Indonesia Menurut Gender Berdasarkan Provinsi” berupaya memberikan pemahaman yang lebih komprehensif mengenai pola perkembangan AHH nasional, kesenjangan antarwilayah, serta ketimpangan antara laki-laki dan perempuan. Hasil analisis ini diharapkan dapat menjadi pijakan awal bagi penyusunan rekomendasi kebijakan kesehatan dan pembangunan yang lebih inklusif dan berbasis bukti. Selain itu, pemahaman mengenai tren AHH berdasarkan gender dan provinsi tidak hanya bermanfaat untuk melihat kondisi kesehatan masyarakat secara makro, tetapi juga penting dalam penyusunan strategi intervensi yang lebih terfokus. Misalnya, jika suatu provinsi menunjukkan AHH perempuan yang meningkat lebih cepat dibanding laki-laki, hal ini dapat mengindikasikan adanya ketimpangan akses atau pola risiko yang berbeda pada laki-laki, seperti paparan pekerjaan berbahaya, kebiasaan merokok yang lebih tinggi, atau keterlambatan akses layanan kesehatan. Sebaliknya, provinsi yang menunjukkan peningkatan AHH laki-laki dan perempuan secara seimbang dapat dijadikan model pembelajaran bagi wilayah lain yang masih tertinggal.

1.2 Tujuan

- 1.2.1 Mengetahui perkembangan tren angka harapan hidup di Indonesia.
- 1.2.2 Membandingkan angka harapan hidup di Indonesia antara laki-laki dengan perempuan.

- 1.2.3 Menganalisis faktor yang memengaruhi harapan hidup di Indonesia antara perempuan dengan laki-laki.
- 1.2.4 Mengidentifikasi pola khusus per wilayah untuk nantinya dibandingkan angka harapan hidup setiap daerah dengan berdasarkan pola khusus tersebut.
- 1.2.5 Membentuk data analisis yang bisa digunakan dalam menentukan langkah selanjutnya.

1.3 Manfaat

- 1.3.1 Memberi Informasi angka harapan hidup kepada pemerintah unruk bisa membentuk kebijakan berkelanjutan
- 1.3.2 Meningkatkan kesadaran publik untuk memperhatikan faktor yang mempengaruhi angka harapan hidup di Indonesia
- 1.3.3 Menjadi referensi analisis lanjutan yang membutuhkan data tren angka harapan hidup di Indonesia berdasarkan gender
- 1.3.4 Diharapkan dapat mengurangi ketimpangan layanan sosial dengan menyoroti hasil analisis angka harapan hidup berdasarkan gender di wilayah yang tertinggal

BAB II

PEMBAHASAN

2.1 Dataset

Dataset berupa file .csv yang memuat informasi tahun, provinsi, dan jumlah Angka Harapan Hidup (AHH) dalam bentuk numerik. Dataset diambil dari tiga sumber berbeda dengan tujuan meningkatkan validasi data yang akan dilakukan analisis. Dataset pertama didapat dari laman Badan Pusat Statistik dengan judul "Angka Harapan Hidup (AHH) Menurut Kabupaten/Kota dan Jenis Kelamin Tahun 2024" yang berisi informasi Provinsi dan Kabupaten/Kota di Indonesia dengan AHH berdasarkan gender pada periode 2024. Selanjutnya dataset kedua didapat dari laman opendata dengan judul "Angka Harapan Hidup Berdasarkan Jenis Kelamin dan Provinsi di Indonesia" yang berisi informasi Kabupaten/Kota di Indonesia dengan AHH berdasarkan gender pada periode 2019. Dataset ketiga didapat dari laman Datast Aceh dengan judul "Angka Harapan Hidup Menurut Jenis Kelamin" yang berisi informasi Provinsi, Kota/Kabupaten, Angka Harapan Hidup, dan jenis kelamin pada periode 2010-2020. Ketiga dataset tersebut berperan sebagai bekal untuk selanjutnya dilakukan ke proses *Integrity checking* sebagai salah satu proses menganalisis.

2.2 Teknik Pengambilan Data dan Integritas Data

2.2.1 Teknik Pengambilan Data

Pengambilan dataset dimulai dari explore pada browser dengan kata kunci 'Angka Harapan Hidup di Indonesia'. Setelah mendapatkan sumber dataset, kami mengambil dataset tersebut secara manual dan mengumpulkannya dalam satu folder drive bersama.

Langkah pertama untuk membaca dataset yang berada di google drive yaitu menghubungkan terlebih dahulu dengan perintah `drive.mount('/content/drive')`. Pastikan perintah tersebut berjalan dengan benar. Untuk memastikan file dataset berada dalam direktori drive yang dihubungkan, jalankan perintah `print(os.listdir('/content/drive/Shares drives/Wrangling/'))` untuk melihat file yang ada pada folder drive yang dihubungkan. Berikut script lengkap membaca dataset dari google drive:

```

from google.colab import drive
drive.mount('/content/drive')

Mounted at /content/drive

import pandas as pd
import glob
import os

print("Isi drive:")
print(os.listdir('/content/drive/Shared drives/Wrangling/'))

Isi drive:
['Angka Harapan Hidup (AHH) Menurut Kabupaten_Kota dan Jenis Kelamin, 2021.csv', 'Angka Harapan Hidup (AHH) Menurut Kabupaten_Kota dan J

path_BPS = '/content/drive/Shared drives/Wrangling/'
path_jabar = '/content/drive/Shared drives/Wrangling/jabar/'
path_aceh = '/content/drive/Shared drives/Wrangling/Aceh/'

```

2.2.2 Integrasi Dataset

a. Dataset BPS

Dalam laman Badan Pusat Statistik (BPS) terdapat beberapa data yang memberikan data AHH dari berbagai tahun. Untuk mendapatkan analisis yang lebih mendalam, kami melakukan integrasi terhadap 17 dataset dari BPS yang menyajikan AHH dengan mengintegrasikan menjadi satu dataset yang disimpan dalam file csv baru. Namun, sebelum menggabungkan kedalam satu file csv baru, kami melakukan cleaning seluruh data dan memberi kolom tahun dan disimpan ke list yang berisi sekumpulan DataFrame tiap tahun. Proses inti pengintegrasian kami lakukan pada script berikut:

```

BPS_all = pd.concat(data_BPS, ignore_index=True)
BPS_all = BPS_all.fillna(0)
BPS_all = BPS_all.dropna(subset=['Provinsi/Kabupaten/Kota'])
BPS_all = BPS_all.reset_index(drop=True)

```

b. Dataset Jabar

Untuk mempermudah pengerjaan ke proses selanjutnya, kami melakukan standarisasi kolom provinsi, jenis kelamin, nilai (AHH) dan tahun pada dataset yang kami dapat dari laman opendata Jawa Barat. Pada script kami juga melakukan cleaning nilai dan format yang belum sesuai. Setelah semua proses itu, dataset disimpan ke dalam file csv baru. Berikut potongan script code untuk mengolah dataset Jawa Barat:

```

for file in filtered_files_jabar:
    print(f"Memproses: {os.path.basename(file)}")

    df = read_csv_auto(file)
    if df.empty:
        print(f"Failed to read or process {os.path.basename(file)}, skipping.")
        continue
    df.columns = [col.strip() for col in df.columns]
    expected_jabar_cols_present = ['nama_provinsi', 'jenis_kelamin', 'angka_harapan_hidup', 'tahun']

    if all(col in df.columns for col in expected_jabar_cols_present):
        temp_df = df.rename(columns={
            'nama_provinsi': 'Provinsi',
            'jenis_kelamin': 'Jenis Kelamin',
            'angka_harapan_hidup': 'Nilai',
            'tahun': 'Tahun'
        })

        temp_df['Nilai'] = pd.to_numeric(temp_df['Nilai'], errors='coerce')
        temp_df = temp_df.dropna(subset=['Nilai'])
        temp_df['Jenis Kelamin'] = temp_df['Jenis Kelamin'].replace({'LAKI-LAKI': 'Laki-laki', 'PEREMPUAN': 'Perempuan'})

```

c. Dataset Aceh

Mengolah dataset yang kami dapat dari provinsi Aceh juga tidak jauh berbeda dengan dataset Jawa Barat. Dataset mentah dilakukan standarisasi setiap nama kolomnya agar mempermudah saat proses integrasi keseluruhan dataset. Setelahnya melakukan cleaning dengan hasil akhir hanya meunculkan kolom yang dibutuhkan. Pada dataset ini kami hanya membutuhkan kolom Provinsi, Jenis kelamin, Angka Harapan Hidup, dan Tahun nya saja. Jadi kolom yang tidak dibutuhkan tidak akan disimpan pada file csv baru yang terbentuk. Berikut cuplikan script code yang kami jalankan:

```

df = read_csv_auto(input_path)
print("Kolom sebelum cleaning:", df.columns.tolist())

column_map = {
    'kemendagri_nama_provinsi': 'Provinsi',
    'jenis_kelamin': 'Jenis Kelamin',
    'angka_harapan_hidup': 'Angka Harapan Hidup',
    'tahun': 'Tahun'
}

df.columns = [col.strip() for col in df.columns]
selected_cols = [col for col in column_map.keys() if col in df.columns]

if len(selected_cols) < len(column_map):
    print("Beberapa kolom yang diharapkan tidak ditemukan di file.")
    print("Kolom ditemukan:", df.columns.tolist())

df_clean = df[selected_cols].copy()
df_clean.rename(columns={k: column_map[k] for k in selected_cols}, inplace=True)

```

d. Integritas Seluruh Dataset

Setelah mengolah dataset persumber, proses selanjutnya melakukan integrasi pada semua csv baru yang terbentuk hasil dari mengolah persumber. Dengan

memanfaatkan pustaka 'pandas' dan 'os' yang mampu memanipulasi data menggabungkan data dari tiga sumber yang berbeda. Langkah pertama membuat salinan dari masing-masing DataFrame yang sudah terbentuk untuk menghindari perubahan pada data asli. Berikut code yang dijalankan untuk membuat salinan DataFrame pada setiap dataset:

```
BPS_std = BPS_all.copy()
BPS_std = BPS_std.melt(
    id_vars=['Provinsi/Kabupaten/Kota', 'Tahun'],
    value_vars=['Laki-laki', 'Perempuan'],
    var_name='Jenis Kelamin',
    value_name='Nilai'
)
```

```
Jabar_std = Jabar_all.copy()
Jabar_std.rename(columns={
    'Provinsi': 'Kabupaten_Provinsi',
    'Nilai': 'Nilai'
}, inplace=True)
```

```
Aceh_std = df_clean.copy()
Aceh_std.rename(columns={
    'Provinsi': 'Kabupaten_Provinsi',
    'Angka Harapan Hidup': 'Nilai'
}, inplace=True)
```

Proses selanjutnya, melakukan standarisasi data setiap sumber agar bisa digabungkan dengan struktur dan kolom yang konsisten. Setelahnya melakukan proses inti, yaitu menggabungkan semua dataset dengan memanfaatkan fungsi `pd.concat` yang menggabungkan dataset menjadi satu DataFrame baru. Lalu DataFrame baru dilakukan handling missing value dimana baris yang memiliki nilai kosong (NaN) pada kolom Kabupaten_Provinsi, Jenis Kelamin, dan Nilai. Pada tahap akhir code akan menyimpan hasilnya dengan membuat file csv baru yang isinya sudah dilakukan standarisasi dan cleaning. Hasil csv tersebut yang digunakan untuk mendapatkan analisis seperti tujuan awal. Berikut cuplikan code yang dijalankan:

```
gabungan_all = pd.concat([BPS_std, Jabar_std, Aceh_std], ignore_index=True)
gabungan_all = gabungan_all.dropna(subset=['Kabupaten_Provinsi', 'Jenis Kelamin', 'Nilai'])
gabungan_all['Kabupaten_Provinsi'] = gabungan_all['Kabupaten_Provinsi'].str.strip().str.title()

gabungan_all = gabungan_all[['Kabupaten_Provinsi', 'Jenis Kelamin', 'Nilai', 'Tahun', 'Sumber']]
gabungan_all = gabungan_all.reset_index(drop=True)

print("Total baris gabungan:", len(gabungan_all))
print(gabungan_all.head())

output_final = os.path.join(output_folder, "gabungan_final_AHH.csv")
gabungan_all.to_csv(output_final, index=False, encoding='utf-8-sig')

print("File gabungan final disimpan ke:", output_final)
```

2.3 Data Cleaning

Data cleaning dilakukan pada csv seluruh dataset yang sudah dilakukan integrasi. Proses detail yang dijalankan pada data cleaning memiliki beberapa langkah pengerjaan. Berikut penjelasan detail *step by step* proses cleaning dataset:

a. Konfigurasi Awal

Langkah pertama mendefinisikan seluruh variable penting penunjang cleaning seperti path input, output, backup, dan penanganan missing value seperti threshold. Berikut code konfigurasi awal pada proses cleaning:

```
INPUT_PATH = "/content/drive/Shared drives/Wrangling/output/gabungan_final_AHH.csv"
CLEANED_OUTPUT_CSV = "/content/drive/Shared drives/Wrangling/output/cleaned_gabungan_final_AHH.csv"
BACKUP_CSV = CLEANED_OUTPUT_CSV.replace(".csv", "_backup_original.csv")
SAVE_PARQUET = True
PARQUET_PATH = CLEANED_OUTPUT_CSV.replace(".csv", ".parquet")
MISSING_COL_THRESHOLD = 0.95
MISSING_ROW_THRESHOLD = 0.5
IMPUTE_NUMERIC = True
IMPUTE_CATEGORICAL = True
FORCE_YEAR_COLUMNS = None
TAKE_YEAR_FROM_RANGE = "first"
```

b. Membaca File

Menambahkan fungsi untuk membaca file bertujuan untuk memeriksa file yang akan dilakukan cleaning. Jika output dari perintah `pd.read_csv` merupakan pesan error, artinya sistem gagal membaca atau file tidak tersedia. Pastikan file yang akan dilakukan cleaning berada dalam direktori yang sama. Berikut cuplikan code untuk membaca file csv secara aman agar mencegah crash dan memberikan feedback:

```
def read_csv_safely(path: str) -> pd.DataFrame:
    if not os.path.exists(path):
        raise FileNotFoundError(f"File tidak ditemukan: {path}")
    print(f"Membaca file: {path}")
    return pd.read_csv(path, low_memory=False)
```


c. Membuat Backup

Backup dibuat untuk menyimpan DataFrame asli ke file backup sebelum melakukan modifikasi. Langkah ini menjadi penting karena memungkinkan rollback jika hasil tidak sesuai harapan. Proses backup menjalankan fungsi `pd.DataFrame` seperti code berikut:

```
def backup_original(df: pd.DataFrame, backup_path: str):  
    print("Membuat backup file asli ke:", backup_path)  
    df.to_csv(backup_path, index=False)
```

d. Membersihkan Nama Kolom

Memanfaatkan regex untuk mengganti spasi, titik, dash, dan slash dengan underscore (`_`). Untuk menyamaratakan bentuk, karakter non-alphanumeric juga dibuang kecuali bentuk underscore (`_`) dan melakukan lowercase dengan menghapus underscore (`_`) ganda. Langkah ini penting untuk menghindari penyebab error saat mengakses dataset. Berikut cuplikan codenya:

```
def clean_column_names(df: pd.DataFrame) -> pd.DataFrame:  
    new_cols = []  
    for c in df.columns:  
        s = str(c).strip()  
        s = s.replace(" ", "_").replace(".", "_").replace("-", "_").replace("/", "_")  
        s = re.sub(r"^[^0-9a-zA-Z_]+$", "", s) # buang karakter aneh  
        s = s.lower()  
        s = re.sub(r"__+", "_", s) # ganti double underscore  
        s = s.strip("_")  
        new_cols.append(s)  
    df.columns = new_cols  
    return df
```

e. Parsing Kolom Tanggal/Waktu

Mendeteksi kolom berdasarkan kata kunci yang menampilkan tahun atau date lalu mengganti keseluruhannya dengan datetime dengan perintah `pd.to_datetime` yang mengansumsikan format DD/MM/YYYY. Langkah ini dilakukan agar bisa dilakukan sort, filter, atau diekstrak. Berikut perintah yang dijalankan dalam code:

```
def parse_datetime_columns(df: pd.DataFrame) -> pd.DataFrame:  
    candidates = [c for c in df.columns if any(k in c.lower() for k in ["date", "tgl", "tanggal", "waktu", "time", "tahun", "year"])]  
    for c in candidates:  
        if pd.api.types.is_datetime64_any_dtype(df[c]):  
            continue  
        try:  
            df[c] = pd.to_datetime(df[c], errors="coerce", dayfirst=True)  
        except Exception:  
            df[c] = pd.to_datetime(df[c], errors="coerce")  
    return df
```

f. Mengonversi Kolom Numerik

Membersihkan separator (koma, spasi non-breaking `\u00A0`) pada kolom yang memiliki digit menggunakan regex dan mengkonversikannya menjadi tipe data

numerik. Hal ini dilakukan sebagai antisipasi jika kolom nilai memiliki tipe data string sebab file berformat csv. Jika kolom terdeteksi berbentuk teks campuran, maka proses akan dilewati dan mencetak pesan peringatan. Konversi ini memungkinkan operasi matematika, jadi jika `errors="coerce"` maka data bersifat invalid dan diubah menjadi NaN. Berikut cuplikan codenya:

```
def convert_numeric_columns(df: pd.DataFrame, sample_size: int = 200) -> pd.DataFrame:
    obj_cols = df.select_dtypes(include=["object", "string"]).columns.tolist()
    for c in obj_cols:
        sample = df[c].dropna().astype(str).head(sample_size)
        if len(sample) == 0:
            continue
        if any(char.isdigit() for val in sample for char in val):
            try:
                cleaned = df[c].astype(str).str.replace(r"[, ]", "", regex=True)
                df[c] = pd.to_numeric(cleaned.replace({"nan": "", "None": ""}), errors="coerce")
            except Exception as e:
                print(f"[convert_numeric_columns] Gagal konversi {c}: {e}")
                continue
    return df
```

g. Membersihkan Kolom Tahun

Pada Langkah ketujuh, system akan membersihkan kolom tahun dengan Auto-detect atau list manual. Jika kolom memiliki tipe data datetime maka ambil tahunnya saja dengan menjalankan `dt.year`. Namun, jika kolom memiliki tipe data string gunakan `extract_year_from_string` untuk mencari empat digit tahun. Setelahnya dikonversi ke Int64 agar NaN dapat ditangani. Berikut script yang dijalankan:

```
def extract_year_from_string(val: Any, prefer: str = "first") -> Optional[int]:
    if pd.isna(val):
        return None
    s = str(val)
    if isinstance(val, (pd.Timestamp, np.datetime64)):
        try:
            return int(pd.to_datetime(val).year)
        except Exception:
            return None
    matches = re.findall(r"\b(19|20)\d{2}\b", s)
    matches_iter = [m.group(0) for m in re.finditer(r"\b(19|20)\d{2}\b", s)]
    if matches_iter:
        if len(matches_iter) == 1:
            return int(matches_iter[0])
        else:
            return int(matches_iter[0]) if prefer == "first" else int(matches_iter[-1])
    m = re.search(r"(19|20)\d{2}", s)
    if m:
        return int(m.group(0))
    return None
```

h. Menghapus Kolom Konstanta

Kolom konstanta tidak memberikan informasi apapun, justru hanya membuang memori. Jadi gunakan `nunique(dropna=False)` untuk menghitung nilai unik termasuk NaN. Jika perhitungan ≤ 1 maka sistem akan menghapus kolom tersebut. Contohnya pada kolom yang menampilkan semua informasi sumber seperti "BPS" atau semua kolom bernilai NaN. Berikut cuplikan codenya:

```
def drop_constant_columns(df: pd.DataFrame) -> Tuple[pd.DataFrame, List[str]]:
    const_cols = [c for c in df.columns if df[c].nunique(dropna=False) <= 1]
    if const_cols:
        print(f"Men-drop {len(const_cols)} kolom konstan.")
        df = df.drop(columns=const_cols)
    return df, const_cols
```

i. Menghapus Kolom dengan Missing Tertinggi

Sistem mendeteksi kolom yang memiliki missing tertinggi berdasarkan perhitungan `df.isna().mean()` yang menghasilkan nilai persentase perkolom nya. Jika hasil persentase $>$ threshold yang sudah didefinisikan pada konfigurasi, maka kolom tersebut akan dihapus. Hal ini dilakukan sebab kolom dengan banyak missing tidak reliable dan bisa distorsi statistik. Berikut code yang dijalankan untuk menghapus kolom dengan missing value tertinggi:

```
def drop_high_missing_columns(df: pd.DataFrame, threshold: float = MISSING_COL_THRESHOLD) -> Tuple[pd.DataFrame, List[str]]:
    missing_pct = df.isna().mean()
    drop_cols = missing_pct[missing_pct > threshold].index.tolist()
    if drop_cols:
        print(f"Men-drop {len(drop_cols)} kolom karena > {threshold*100:.0f}% missing.")
        df = df.drop(columns=drop_cols)
    return df, drop_cols
```

j. Menghapus Duplikat Eksak

Langkah ini akan menghapus salah satu dari 2 baris yang memiliki nilai identik. Hal ini dilakukan untuk menghindari terjadi inflasi hasil yang disebabkan oleh adanya kesamaan identik pada baris yang berbeda. Untuk menghapus duplikat eksak kita harus membandingkan antar baris dengan menjalankan fungsi `drop_duplicates()` seperti code dibawah ini:

```
def remove_exact_duplicates(df: pd.DataFrame) -> Tuple[pd.DataFrame, int]:
    before = df.shape[0]
    df = df.drop_duplicates().reset_index(drop=True)
    removed = before - df.shape[0]
    if removed > 0:
        print(f"Removed {removed} exact duplicate rows (double identik).")
    return df, removed
```

k. Handling Missing Value

Baris yang memiliki $>50\%$ kolom missing akan dihapus, keputusan ini merujuk pada konfigurasi nilai threshold. Missing value juga ditangani dengan menginput nilai median pada kolom numeric dan mode pada kolom object atau string. Penanganan ini

dilakukan untuk menghindari error tanpa harus menghapus seluruh data yang tidak memiliki value. Output nya berupa DataFrame yang seluruhnya sudah memiliki value seperti yang dijalankan oleh code berikut:

```
def handle_missing_values(df: pd.DataFrame,
                          drop_row_threshold: Optional[float] = MISSING_ROW_THRESHOLD,
                          impute_numeric: bool = IMPUTE_NUMERIC,
                          impute_categorical: bool = IMPUTE_CATEGORICAL) -> Tuple[pd.DataFrame, Dict[str, Any]]:
    actions = {"dropped_rows": 0, "imputed_numeric": [], "imputed_categorical": []}
```

Dataset yang telah melewati proses cleaning berbagai tahap akan disimpan dalam file csv baru yang menampilkan dataset bersih tanpa missing value dan telah disesuaikan dengan tujuan akhir analisis.

2.4 Preprocessing

Dataset yang sudah dilakukan cleaning akan dilakukan preprocessing untuk memastikan dataset siap digunakan untuk menganalisis. Detail proses dalam preprocessing tidak jauh berbeda dari proses cleaning, dimulai dari membaca file hasil cleaning kemudian dilanjutkan dengan menormalkan nama kolom agar konsisten dan kolom kunci seperti provinsi, nilai AHH, tahun, dan gender dapat terdeteksi secara otomatis. Selanjutnya kolom tahun dinormalkan menjadi format integer standar, kolom AHH dikonversi ke numerik, dan data difilter untuk baris dengan tahun valid.

Langkah utama dari preprocessing mengagregasi data berdasarkan provinsi dan tahun untuk menghitung rata-rata, median, dan jumlah observasi AHH, yang kemudian disimpan sebagai file CSV dasar. Script preprocessing membangun panel data lengkap untuk setiap provinsi dengan mengisi tahun yang hilang dari rentang minimum hingga maksimum, menggunakan interpolasi linear untuk mengisi nilai AHH yang missing, dan menghitung metrik tren seperti rata-rata rolling 3-tahun, perbedaan year-over-year, serta persentase perubahan year-over-year, sambil mengisi missing values dengan rata-rata global. Proses serupa juga dilakukan dengan melakukan agregasi dan tren berdasarkan provinsi, gender, dan tahun. Semua hasilnya disimpan dalam file CSV terpisah untuk agregasi dan tren yang telah diproses untuk mempermudah proses visualisasi. Berikut cuplikan hasil CSV yang terbentuk:

```
df = pd.read_csv("/content/drive/Shared drives/Wrangling/output/processed_trend_AHH_province.csv")
df.head()
```

	province	year	ahh_mean	ahh_median	observations	ahh_rolling_3	ahh_yoy_diff	ahh_yoy_pct
0	Aceh	2010	67.331458	67.255	48	67.331458	NaN	NaN
1	Aceh	2011	67.390417	67.315	48	67.360938	0.058958	0.000876
2	Aceh	2012	67.438125	67.370	48	67.386667	0.047708	0.000708
3	Aceh	2013	67.473958	67.420	48	67.434167	0.035833	0.000531
4	Aceh	2014	67.492083	67.445	48	67.468056	0.018125	0.000269


```
df = pd.read_csv("/content/drive/Shared drives/Wrangling/output/processed_trend_AHH_province_gender.csv")
df.head()
```

	province	gender	year	ahh_mean	ahh_median	observations	ahh_rolling_3	ahh_yoy_diff	ahh_yoy_pct
0	Aceh	Laki-laki	2010	65.426250	66.220	24	65.426250	NaN	NaN
1	Aceh	Laki-laki	2011	65.484167	66.275	24	65.455208	0.057917	0.000885
2	Aceh	Laki-laki	2012	65.531250	66.300	24	65.480556	0.047083	0.000719
3	Aceh	Laki-laki	2013	65.567083	66.340	24	65.527500	0.035833	0.000547
4	Aceh	Laki-laki	2014	65.585000	66.360	24	65.561111	0.017917	0.000273

2.5 Exploratory Data Analysis (EDA)

a. Mengetahui Perkembangan Angka Harapan Hidup di Indonesia

Berdasarkan file csv yang terbentuk dari hasil cleaning, kita dapat mengetahui Tren Angka Harapan Hidup Nasional dari tahun 2010 hingga 2024 dengan membuat visualisasi yang ramah dimengerti orang awam. Berikut grafik yang terbentuk untuk melihat Angka Harapan Hidup berdasarkan tahun:




Melihat grafik tersebut kita dapat menginterpretasikan dari bentuknya. Grafik menunjukkan tren AHH keseluruhan meningkat secara stabil. Pada tahun 2010 hingga 2015 naik secara bertahap sekitar 68,2 tahun menjadi 68,65 tahun. Kenaikan ini bersifat kontinu namun lambat, secara kasat mata kenaikannya terlihat mulus tanpa lonjakan besar yang menunjukkan peningkatan fase ini terjadi secara evolutif.

Selanjutnya tahun 2016 terjadi kenaikan besar, dari 68,65 tahun menjadi 69,45 tahun. Hal ini bisa jadi disebabkan oleh dampak program kesehatan nasional, peningkatan akses layanan kesehatan dasar, penurunan angka kematian bayi dan ibu, dsb. Dari tahun 2016 terjadi penurunan sekitar 68,85 pada tahun 2017. Namun, jika melihat grafik keseluruhan, penurunan hanya bersifat sementara sebab grafik kembali naik secara stabil dan signifikan pada tahun 2018 hingga 2024. Dari 69,07 menjadi 70,5 tahun. Peningkatan yang stabil menandakan arah positif dalam pembangunan kesehatan Indonesia.


b. Membandingkan angka harapan hidup laki-laki dan Perempuan

Dari dataset yang tersedia, kami dapat membandingkan AHH berdasarkan gendernya. Visualisasi ini dibuat dalam bentuk boxplot untuk mempermudah khalayak umum dalam memahami persebaran datanya. Berikut boxplot yang terbentuk:



Interpretasi dari boxplot yang terbentuk, terdapat perbedaan nilai median antara AHH laki-laki dengan AHH perempuan, Median AHH laki-laki berada di angka 68-69 tahun, sedangkan median AHH perempuan lebih tinggi dari laki-laki dengan angka 71-72 tahun. Jika dilihat dari perbedaan nilai tengah, perempuan di Indonesia hidup lebih lama dibanding laki-laki. Ini sesuai dengan pola global bahwa perempuan biasanya memiliki harapan hidup lebih tinggi.


Rentang pesebaran utama atau nilai IQR laki-laki lebih rendah, sekitar 65-69 tahun sedangkan nilai IQR perempuan berada pada rentang 69-73 tahun. Dapat disimpulkan Mayoritas nilai AHH perempuan tidak hanya lebih tinggi, tetapi juga lebih stabil. Dari boxplot dapat dilihat nilai whisker yang menunjukkan rentang data tanpa outlier, dengan detail nilai laki-laki sekitar 58-77 tahun sedangkan perempuan sekitar 62-80 tahun. Namun, dari boxplot juga menunjukkan banyak outlier yang artinya ada beberapa wilayah atau daerah dengan AHH jauh lebih rendah dibanding rata-rata nasional.



Visualisasi kedua untuk membandingkan angka harapan hidup laki-laki dan Perempuan yang disertai tahun dibuat dalam bentuk grafik yang mudah dipahami. Garis biru menggambarkan data untuk laki-laki sedangkan garis orange ditujukan untuk data perempuan. Secara konsisten, perempuan memiliki AHH lebih tinggi yang artinya Perempuan selalu hidup rata-rata 3-4 tahun lebih lama daripada laki-laki. Namun, dari grafik yang terbentuk, baik laki-laki maupun perempuan mengalami kenaikan bertahap setiap tahunnya.

Kenaikan signifikan terjadi pada tahun 2016 dimana AHH laki-laki naik dari 66,8 menjadi 67,6 dan AHH perempuan naik dari 70,5 menjadi 71,4. Setelahnya pada tahun 2017 terjadi penurunan sementara dan dilanjutkan dengan kenaikan stabil dari tahun 2018 hingga 2024. Jadi inti dari grafik tersebut adalah Perempuan memiliki tingkat kelangsungan hidup lebih baik karena beberapa faktor biologis dan gaya hidup.

Rata-Rata AHH Laki-Laki dan Perempuan di Indonesia (Semua Tahun)



Data yang digunakan untuk membuat Tren AHH berdasarkan gender dapat digunakan untuk mencari rata-rata dari data tersebut. Data pada periode 2010 hingga 2024 masing-masing gender memiliki nilai rata-rata 67.208 untuk laki-laki dan 71.031 untuk perempuan. Artinya, secara umum perempuan di Indonesia diperkirakan hidup lebih lama dibanding laki-laki. Hal ini sejalan dengan tren global bahwa perempuan cenderung memiliki harapan hidup lebih tinggi dibanding laki-laki.

c. Menganalisis faktor yang memengaruhi AHH laki-laki vs Perempuan

Memanfaatkan pustaka pandas data melakukan grouping untuk menganalisis AHH antara laki-laki dengan perempuan berdasarkan tahun. Menghitung rata-rata AHH per tahun dan jenis kelamin, kemudian menghitung selisih (gap) antara AHH perempuan dan laki-laki. Outputnya adalah DataFrame yang menunjukkan tren gap ini, yang bisa digunakan untuk mengidentifikasi pola atau faktor yang memengaruhi perbedaan AHH antar gender. Berikut output yang dihasilkan dari proses grouping:


```
df.groupby("Jenis Kelamin")["Nilai"].describe()
```

	count	mean	std	min	25%	50%	75%	max
Jenis Kelamin								
Laki-laki	8056.0	67.208126	3.553785	50.98	65.00	67.44	69.57	76.40
Perempuan	8058.0	71.031410	3.597133	54.22	68.85	71.32	73.43	80.38

Tahun	Laki-laki	Perempuan	gap_perempuan_laki
2010	66.347.907	70.086.402	3.738.495
2011	66.370.596	70.131.604	3.761.008
2012	66.441.115	70.212.937	3.771.822
2013	66.479.631	70.251.775	3.772.144
2014	66.548.864	70.321.119	3.772.255
2015	66.746.853	70.519.843	3.772.990
2016	67.534.000	71.363.429	3.829.429
2017	66.959.476	70.796.783	3.837.308
2018	67.158.007	70.998.269	3.840.262
2019	67.446.106	71.292.525	3.846.419
2020	67.607.657	71.433.317	3.825.660
2021	67.775.214	71.604.322	3.829.108
2022	67.995.969	71.900.360	3.904.391
2023	68.356.346	72.269.400	3.913.053
2024	68.517.794	72.452.297	3.934.503


Dari proses tersebut, faktor yang dapat dianalisis yaitu Tren temporal yang melihat apakah gap meningkat, menurun, atau stabil dari tahun ke tahun, dan faktor penyebab potensial. Selain itu kita dapat melihat faktor penyebab potensial berdasarkan gap positif (perempuan > laki-laki) yang mungkin disebabkan oleh gaya hidup laki-laki yang lebih berisiko seperti merokok dan melakukan pekerjaan berbahaya. Sedangkan gap negatifnya bisa disebabkan dari faktor kesehatan perempuan seperti kanker payudara. Hasil gap yang telah dianalisis dapat dijadikan rujukan pembentukan kebijakan oleh pemerintah seperti mengidentifikasi area intervensi.



Hasil DataFrame yang dihasilkan sebelumnya dapat divisualisasikan menjadi grafik gap AHH berdasarkan gender di Indonesia per tahunnya. Grafik yang terbentuk menunjukkan bahwa Angka Harapan Hidup (AHH) perempuan di Indonesia secara konsisten lebih tinggi daripada laki-laki selama periode 2010 hingga 2024. Selisih AHH kisaran 3.7 hingga 4.0 tahun sepanjang periode yang diamati.

d. Mengidentifikasi pola khusus per wilayah

Nilai AHH memiliki pola khusus berdasarkan dari kondisi wilayah yang berbeda. Pola khusus per wilayah dapat divisualisasikan menggunakan heatmap AHH tiap provinsi pada setiap tahunnya. Berikut heatmap yang terbentuk:






Heatmap tersebut dapat diinterpretasikan dimana setiap baris mewakili satu kabupaten/kota lalu setiap kolomnya mewakili tahun. Warna yang lebih gelap berarti nilai AHH lebih tinggi dan garis warna yang lebih terang menandakan nilai AHH lebih rendah. Dapat disimpulkan terdapat kesenjangan nyata antar-wilayah terkait kualitas kesehatan dan kesejahteraan masyarakat. Pola umum yang terlihat hampir semua daerah mengalami kenaikan dari tahun 2010 hingga 2024 sehingga menunjukkan tren nasional meningkat.

Daerah perkotaan dengan ekonomi yang lebih maju memiliki nilai AHH lebih tinggi seperti Kota Jakarta Selatan, Kota Semarang, Kota Tangerang, Kota Padang Panjang, Kepulauan Bangka Belitung dan Kota Batam. Sedangkan daerah dengan geografis cenderung memiliki AHH lebih rendah. Pada tahun 2026 terlihat banyak kotak putih yang menandakan data tidak tersedia atau kosong. Daerah dengan daerah dari warna terang menjadi lebih gelap secara cepat seperti Jombang, Karangasem, dan Lampung Selatan memiliki arti daerah tersebut memiliki perbaikan yang cepat. Terakhir, kota yang warnanya tidak berubah banyak berarti daerah tersebut tergolong relatif stabil.

e. Tren AHH lima Provinsi Tertinggi

Grafik memperlihatkan tren Angka Harapan Hidup (AHH) dari tahun 2010–2024 pada lima daerah dengan AHH tertinggi. Berikut grafik yang terbentuk untuk mengetahui Tren AHH lima provinsi Tertinggi:





Jelas terlihat bahwa Sukorharjo memiliki nilai AHH paling tinggi. Sejak tahun 2010 hingga 2024 kurvanya selalu berada di atas daerah lainnya, pada tahun 2024 nilai AHH sukoharjo mencapai 80,3 tahun. Disusul oleh Kota Semarang dan Karanganyar yang berada di posisi menengah-atas dengan peningkatan yang relatif stabil dan konsisten. Hingga pada akhir dataset tahun 2024 Kota Semarang dan Karanganyar memiliki nilai 80,0-80,1 tahun. Dua provinsi yang memiliki nilai AHH tertinggi adalah Kota Surakarta da Kota Salatiga yang menunjukkan pola peningkatan yang stabail dan pada tahun 2024 keduanya mencapai sekitar 79,9-80 tahun.

Pola yang terbentuk dari grafik tren tersebut yaitu terjadi peningkatan jangka panjang pada semua daerah, terjadi penurunan sementara pada tahun 2010-2015, namun itu bisa saja merupakan variasi data dan bukan penurunan nyata. Jika meninjau lebih lanjut, terjadi lonjakan signifikan dari tahun 2023 ke tahun 2024. Peningkatan ini dapat terjadi dikarenakan adanya Perbaikan data pasca pandemi, dilakukan evaluasi sistem data kesehatan yang baru, dan adanya peningkatan layanan kesehatan signifikan (misal program pasca-COVID). Berikut detail nilai AHH tertinggi pada 5 Provinsi:

Kabupaten_Provinsi	Nilai
Sukoharjo	77.645.357
Kota Semarang	77.404.286
Karanganyar	77.221.786
Kota Surakarta	77.186.071
Kota Salatiga	77.084.643

Grafik kedua yang menampilkan tren AHH 5 provinsi tertinggi pada gender laki-laki menunjukkan peningkatan yang kuat dan konsisten sepanjang periode 2010 hingga 2024, dengan semua wilayah mencapai AHH di atas 75.8 tahun pada 2024. Sedangkan pada grafik ketiga yang menampilkan tren AHH 5 provinsi tertinggi pada gender perempuan memiliki nilai lebih tinggi, sekitar 78,5 hingga 80,3 tahun. Dari tren berdasarkan gender tersebut, peringkat terbawah pada gender laki-laki ada di wilayah Karanganyar sedangkan pada gender perempuan berada di wilayah Kota Salatiga.

f. Membentuk data analisis untuk langkah selanjutnya

Terdapat beberapa Langkah yang dapat dilakukan pada data untuk melakukan analisis lanjutan. Berikut proses yang dijalankan sebelum melakukan langkah modelling:

- Analisis Statistik Dekriptif Per Tahun
Melakukan analisis statistik deskriptif menggunakan perintah `df.groupby` untuk melihat perkembangan nilai per tahun. Outputnya berupa statistik yang membantu memahami bagaimana nilai berubah dari tahun ke tahun. Berikut output yang dihasilkan:

Tahun	mean	median	min	max	std
2010	68.220.610	68.350	50.98	79.31.00	4.177.809
2011	68.252.795	68.380	51.42.00	79.33.00	4.156.780
2012	68.325.329	68.420	51.74	79.35.00	4.129.175
2013	68.365.703	68.460	51.86	79.37.00	4.115.699
2014	68.434.991	68.490	51.92	79.38.00	4.084.502
2015	68.633.348	68.680	52.42.00	79.43.00	4.029.995
2016	69.448.714	69.220	62.49.00	76.54.00	3.245.416
2017	68.878.129	68.950	52.92	79.45.00	4.005.867
2018	69.078.138	69.120	53.17.00	79.50.00	3.967.374
2019	69.369.315	69.440	53.42.00	79.52.00	3.878.507
2020	69.520.487	69.580	53.57.00	79.61	3.855.305
2021	69.689.768	69.815	53.71	79.72	3.868.442
2022	69.948.165	70.095	53.86	79.83	3.852.973
2023	70.312.873	70.390	54.08.00	79.88	3.831.393
2024	70.485.045	70.560	54.22.00	80.38.00	3.901.701

- Analisis Berdasarkan Wilayah
Proses ini melakukan pengelompokan data berdasarkan wilayah dan menghitung statistik deskriptif. Outputnya berguna untuk membandingkan kualitas atau tingkat antar daerah dan mengidentifikasi daerah dengan nilai tertinggi atau terendah. Berikut cuplikan outputnya:

	mean	median	min	max	std
Kabupaten_Provinsi					
Aceh	67.812460	67.755	60.72	73.47	2.984672
Aceh Barat	67.668571	67.770	65.20	70.52	2.040219
Aceh Barat Daya	64.440000	64.490	61.55	67.63	2.073723
Aceh Besar	69.633929	69.795	67.34	72.31	2.009572
Aceh Jaya	66.836429	66.935	64.35	69.73	2.029178
...	...	...	...	...	...
Way Kanan	68.761786	68.870	65.67	72.18	2.173148
Wonogiri	76.041429	76.215	73.56	78.84	1.983901
Wonosobo	71.312857	71.315	68.44	74.45	2.069394
Yahukimo	65.353214	65.415	62.51	68.52	2.095192
Yalimo	65.160000	65.285	62.82	68.10	1.965301


- Perbedaan Nilai Berdasarkan Jenis Kelamin.
Selanjutnya melakukan perbedaan nilai berdasarkan jenis kelamin dengan mengelompokkan data berdasarkan kolom gender lalu menghitung statistik deskriptifnya untuk masing-masing gender. Analisis ini berguna untuk menganalisis apakah terdapat perbedaan signifikan nilai AHH antar gender. Berikut output yang dihasilkan:

Jenis Kelamin	mean	median	min	max	std
Laki-laki	67.208.126	67.44.00	50.98	76.40.00	3.553.785
Perempuan	71.031.410	71.32.00	54.22.00	80.38.00	3.597.133

- Dataset untuk modelling
Analisis menyeluruh akan mengantarkan ke proses modelling yang akan dibentuk. Proses ini mengambil kolom yang relevan untuk modelling (data reduction) seperti wilayah, jenis kelamin, tahun, dan nilai AHH. Lalu memastikan nilai missing terhapus dengan perintah `.dropna()` yang selanjutnya menyimpan ke file csv. Berikut cuplikan output yang dihasilkan:


	Kabupaten_Provinsi	Jenis Kelamin	Tahun	Nilai
0	Aceh	Laki-laki	2010	67.17
1	Simeulue	Laki-laki	2010	62.15
2	Aceh Singkil	Laki-laki	2010	64.76
3	Aceh Selatan	Laki-laki	2010	61.04
4	Aceh Tenggara	Laki-laki	2010	64.90

- Tren AHH 5 Provinsi dengan Nilai Rata-Rata Tertinggi
 Code akan mengambil 10 provinsi dengan rata-rata AHH tertinggi dengan mengelompokkan berdasarkan wilayah dan menghitung rata-rata AHH di setiap provinsi. Dari 10 provinsi tersebut hanya diambil 5 provinsi teratas. Selanjutnya dibuat plot trennya yang menghubungkan tahun dengan nilai AHH. Berikut output yang dikeluarkan:



- Tren AHH 5 Provinsi Tertinggi Berdasarkan Jenis Kelamin
 Dengan menggunakan daftar 5 provinsi tertinggi dilakukan looping setiap provinsi untuk menampilkan grafik tren AHH dari tahun ke tahun pada 5 provinsi terbaik yang dipisahkan berdasarkan jenis kelamin (Laki-laki & Perempuan). Tujuan visualisasi ini yaitu Membandingkan apakah ada gap gender dalam AHH dan

mendapatkan insight untuk analisis lanjutan atau modeling. Berikut output yang dihasilkan:



2.6 Data Publishing

2.6.1 Row Data

Project ini menggunakan 3 dataset dengan format csv yang masing-masing dataset memiliki nilai AHH, kabupaten/kota, dan gender. Berikut penjelasan masing-masing dataset yang digunakan:

- Dataset 1

Provinsi/Kabupaten/Kota							
	Angka Harapan Hidup (AHH) Menurut Kabupaten/Kota dan Jenis Kelamin (Tahun)						
	Laki-laki	Perempuan					
	2010	2010					
ACEH	67.17	71.09					
Simeulue	62.15	65.84					
Aceh Singkil	64.76	68.55					
Aceh Selatan	61.04	64.69					
Aceh Tenggara	64.9	68.69					
Aceh Timur	65.95	69.77					
Aceh Tengah	66.24	70.08					
Aceh Barat	65.2	69					
Aceh Besar	67.34	71.22					
Pidie	64.2	67.97					
Bireuen	68.26	72.17					
Aceh Utara	66.34	70.18					
Aceh Barat Daya	61.55	65.22					
Gayo Lues	62.34	66.03					
Aceh Tamiang	66.59	70.44					
Nagan Raya	66.2	70.03					
Aceh Jaya	64.35	68.12					
Bener Meriah	66.53	70.38					
Pidie Jaya	67.02	70.88					
Kota Banda Aceh	68.69	72.62					
Kota Sabang	67.52	71.4					
Kota Langsa	66.66	70.52					
Kota Lhokseumawe	68.51	72.43					

Row data untuk dataset BPS diambil dari publikasi resmi Badan Pusat Statistik (BPS) dengan judul Angka Harapan Hidup Menurut Kabupaten/Kota dan Jenis Kelamin. Dataset ini tersedia secara terpisah per tahun untuk periode 2010 hingga 2024, dan seluruh file diunduh untuk kepentingan project pada tanggal 11 November 2025 dalam bentuk berkas CSV. Setiap file berisi nama kabupaten/kota, angka harapan hidup penduduk laki-laki, serta angka harapan hidup penduduk perempuan pada tahun tersebut. Format data BPS memisahkan nilai AHH berdasarkan jenis kelamin pada dua kolom numerik, sehingga memudahkan analisis perbandingan gender dan tren tahunan di level kabupaten/kota. Karena bersumber langsung dari BPS, dataset ini memiliki validitas tinggi dan menjadi dasar penting dalam analisis perkembangan angka harapan hidup di Indonesia sepanjang 15 tahun terakhir.

- Dataset 2

id	kode_provinsi	nama_provinsi	jenis_kelamin	angka_harapan_hidup	satuan	tahun
1	11	ACEH	LAKI-LAKI	67.98	TAHUN	2019
2	11	ACEH	PEREMPUAN	71.85	TAHUN	2019
3	12	SUMATERA UTARA	LAKI-LAKI	67.07	TAHUN	2019
4	12	SUMATERA UTARA	PEREMPUAN	70.92	TAHUN	2019
5	13	SUMATERA BARAT	LAKI-LAKI	67.42	TAHUN	2019
6	13	SUMATERA BARAT	PEREMPUAN	71.29	TAHUN	2019
7	14	RIAU	LAKI-LAKI	69.62	TAHUN	2019
8	14	RIAU	PEREMPUAN	73.43	TAHUN	2019
9	15	JAMBI	LAKI-LAKI	69.11	TAHUN	2019
10	15	JAMBI	PEREMPUAN	72.97	TAHUN	2019
11	16	SUMATERA SELATAN	LAKI-LAKI	67.78	TAHUN	2019
12	16	SUMATERA SELATAN	PEREMPUAN	71.63	TAHUN	2019
13	17	BENGKULU	LAKI-LAKI	67.28	TAHUN	2019
14	17	BENGKULU	PEREMPUAN	71.13	TAHUN	2019
15	18	LAMPUNG	LAKI-LAKI	68.64	TAHUN	2019
16	18	LAMPUNG	PEREMPUAN	72.48	TAHUN	2019
17	19	KEPULAUAN BANGKALAN	LAKI-LAKI	68.63	TAHUN	2019
18	19	KEPULAUAN BANGKALAN	PEREMPUAN	72.46	TAHUN	2019
19	21	KEPULAUAN RIAU	LAKI-LAKI	67.92	TAHUN	2019
20	21	KEPULAUAN RIAU	PEREMPUAN	71.73	TAHUN	2019
21	31	DKI JAKARTA	LAKI-LAKI	70.96	TAHUN	2019
22	31	DKI JAKARTA	PEREMPUAN	74.68	TAHUN	2019
23	32	JAWA BARAT	LAKI-LAKI	71.03	TAHUN	2019
24	32	JAWA BARAT	PEREMPUAN	74.81	TAHUN	2019
25	33	JAWA TENGAH	LAKI-LAKI	72.33	TAHUN	2019

Row data diambil dari laman Open data Jabar pada judul Angka Harapan Hidup Berdasarkan Jenis Kelamin dan Provinsi di Indonesia yang diperbarui pada tahun 2024. Row data diunduh untuk kepentingan project pada tanggal 11 November 2025 dengan format CSV. Data berisi informasi id, kode_provinsi, nama_provinsi, jenis_kelamin, angka_harapan_hidup, satuan, dan tahun.

- Dataset 3

kemendagri_kode_pr	kemendagri_nama_r	kemendagri_kode_ke	kemendagri_nama_k	tahun	jenis_kelamin	angka_harapan_hidup	satuan
11	Aceh	11.01	Kabupaten Aceh Sel	2010	Laki-Laki	61.04	Tahun
11	Aceh	11.02	Kabupaten Aceh Te	2010	Laki-Laki	64.9	Tahun
11	Aceh	11.03	Kabupaten Aceh Tin	2010	Laki-Laki	65.95	Tahun
11	Aceh	11.04	Kabupaten Aceh Te	2010	Laki-Laki	66.24	Tahun
11	Aceh	11.05	Kabupaten Aceh Bai	2010	Laki-Laki	65.2	Tahun
11	Aceh	11.06	Kabupaten Aceh Be	2010	Laki-Laki	67.34	Tahun
11	Aceh	11.07	Kabupaten Pidie	2010	Laki-Laki	64.2	Tahun
11	Aceh	11.08	Kabupaten Aceh Uta	2010	Laki-Laki	66.34	Tahun
11	Aceh	11.09	Kabupaten Simeuluk	2010	Laki-Laki	62.15	Tahun
11	Aceh	11.1	Kabupaten Aceh Sin	2010	Laki-Laki	64.76	Tahun
11	Aceh	11.11	Kabupaten Bireuen	2010	Laki-Laki	68.26	Tahun
11	Aceh	11.12	Kabupaten Aceh Bai	2010	Laki-Laki	61.55	Tahun
11	Aceh	11.13	Kabupaten Gayo Lu	2010	Laki-Laki	62.34	Tahun
11	Aceh	11.14	Kabupaten Aceh Jay	2010	Laki-Laki	64.35	Tahun
11	Aceh	11.15	Kabupaten Nagan Ri	2010	Laki-Laki	66.2	Tahun
11	Aceh	11.16	Kabupaten Aceh Tai	2010	Laki-Laki	66.59	Tahun
11	Aceh	11.17	Kabupaten Bener Me	2010	Laki-Laki	66.53	Tahun
11	Aceh	11.18	Kabupaten Pidie Jay	2010	Laki-Laki	67.02	Tahun
11	Aceh	11.71	Kota Banda Aceh	2010	Laki-Laki	68.69	Tahun
11	Aceh	11.72	Kota Sabang	2010	Laki-Laki	67.52	Tahun
11	Aceh	11.73	Kota Lhokseumawe	2010	Laki-Laki	68.51	Tahun
11	Aceh	11.74	Kota Langsa	2010	Laki-Laki	66.66	Tahun
11	Aceh	11.75	Kota Subulussalam	2010	Laki-Laki	60.72	Tahun
11	Aceh	11.01	Kabupaten Aceh Sei	2010	Perempuan	64.69	Tahun
11	Aceh	11.02	Kabupaten Aceh Te	2010	Perempuan	68.69	Tahun

Row data diambil dari laman Open Data Aceh dengan judul Angka Harapan Hidup menurut Jenis Kelamin yang diperbarui pada tanggal 20 Juli 2023. Row data diunduh untuk kepentingan project pada tanggal 13 November 2025 dengan format CSV. Data berisi informasi mengenai kemendagri_kode_provinsi, kemendagri_nama_provinsi, kemendagri_kode_kecamatan, kemendagri_nama_kesamatan, tahun, jenis_kelamin, angka_harapan_hidup, dan satuan.

2.6.2 Hasil Proses Wrangling

- Integrasi Dataset

Provinsi/Kabupaten/Kota	Laki-laki	Perempuan	Tahun
ACEH	67.17	71.09	2010
Simeulue	62.15	65.84	2010
Aceh Singkil	64.76	68.55	2010
Aceh Selatan	61.04	64.69	2010
Aceh Tenggara	64.9	68.69	2010
Aceh Timur	65.95	69.77	2010
Aceh Tengah	66.24	70.08	2010
Aceh Barat	65.2	69	2010
Aceh Besar	67.34	71.22	2010
Pidie	64.2	67.97	2010
Bireuen	68.26	72.17	2010
Aceh Utara	66.34	70.18	2010
Aceh Barat Daya	61.55	65.22	2010
Gayo Lues	62.34	66.03	2010
Aceh Tamiang	66.59	70.44	2010
Nagan Raya	66.2	70.03	2010
Aceh Jaya	64.35	68.12	2010
Bener Meriah	66.53	70.38	2010
Pidie Jaya	67.02	70.88	2010
Kota Banda Aceh	68.69	72.62	2010
Kota Sabang	67.52	71.4	2010
Kota Langsa	66.66	70.52	2010
Kota Lhokseumawe	68.51	72.43	2010
Kota Subulussalam	60.72	64.36	2010
SUMATERA UTARA	65.59	69.43	2010

Seluruh dataset yang diunduh dari laman BPS disimpan dalam satu file CSV dengan kolom Provinsi/Kabupaten/Kota, Laki-Laki, Perempuan, dan Tahun.

Provinsi	Jenis Kelamin	Nilai	Tahun
ACEH	Laki-laki	67.98	2019
ACEH	Perempuan	71.85	2019
SUMATERA UTARA	Laki-laki	67.07	2019
SUMATERA UTARA	Perempuan	70.92	2019
SUMATERA BARAT	Laki-laki	67.42	2019
SUMATERA BARAT	Perempuan	71.29	2019
RIAU	Laki-laki	69.62	2019
RIAU	Perempuan	73.43	2019
JAMBI	Laki-laki	69.11	2019
JAMBI	Perempuan	72.97	2019
SUMATERA SELATAN	Laki-laki	67.78	2019
SUMATERA SELATAN	Perempuan	71.63	2019
BENGKULU	Laki-laki	67.28	2019
BENGKULU	Perempuan	71.13	2019
LAMPUNG	Laki-laki	68.64	2019
LAMPUNG	Perempuan	72.48	2019
KEPULAUAN BANGKALAN	Laki-laki	68.63	2019
KEPULAUAN BANGKALAN	Perempuan	72.46	2019
KEPULAUAN RIAU	Laki-laki	67.92	2019
KEPULAUAN RIAU	Perempuan	71.73	2019
DKI JAKARTA	Laki-laki	70.96	2019
DKI JAKARTA	Perempuan	74.68	2019
JAWA BARAT	Laki-laki	71.03	2019
JAWA BARAT	Perempuan	74.81	2019
JAWA TENGAH	Laki-laki	72.33	2019

Dataset yang diunduh dari Open Data Jabar dilakukan cleaning sebelum diintegrasikan ke seluruh dataset disimpan dalam file CSV yang berisi informasi Provinsi, Jenis Kelamin, Nilai, dan Tahun.

Provinsi	Jenis Kelamin	Angka Harapan Hidup	Tahun
Aceh	Laki-laki	61.04	2010
Aceh	Laki-laki	64.9	2010
Aceh	Laki-laki	65.95	2010
Aceh	Laki-laki	66.24	2010
Aceh	Laki-laki	65.2	2010
Aceh	Laki-laki	67.34	2010
Aceh	Laki-laki	64.2	2010
Aceh	Laki-laki	66.34	2010
Aceh	Laki-laki	62.15	2010
Aceh	Laki-laki	64.76	2010
Aceh	Laki-laki	68.26	2010
Aceh	Laki-laki	61.55	2010
Aceh	Laki-laki	62.34	2010
Aceh	Laki-laki	64.35	2010
Aceh	Laki-laki	66.2	2010
Aceh	Laki-laki	66.59	2010
Aceh	Laki-laki	66.53	2010
Aceh	Laki-laki	67.02	2010
Aceh	Laki-laki	68.69	2010
Aceh	Laki-laki	67.52	2010
Aceh	Laki-laki	68.51	2010
Aceh	Laki-laki	66.66	2010
Aceh	Laki-laki	60.72	2010
Aceh	Perempuan	64.69	2010
Aceh	Perempuan	68.69	2010

Dataset yang diunduh dari Open Data Aceh dilakukan cleaning sebelum diintegrasikan ke seluruh dataset disimpan dalam file CSV yang berisi informasi Provinsi, Jenis Kelamin, Angka Harapan Hidup, dan Tahun.

Kabupaten_Provinsi	Jenis Kelamin	Nilai	Tahun	Sumber
Aceh	Laki-laki	67.17	2010	BPS
Simeulue	Laki-laki	62.15	2010	BPS
Aceh Singkil	Laki-laki	64.76	2010	BPS
Aceh Selatan	Laki-laki	61.04	2010	BPS
Aceh Tenggara	Laki-laki	64.9	2010	BPS
Aceh Timur	Laki-laki	65.95	2010	BPS
Aceh Tengah	Laki-laki	66.24	2010	BPS
Aceh Barat	Laki-laki	65.2	2010	BPS
Aceh Besar	Laki-laki	67.34	2010	BPS
Pidie	Laki-laki	64.2	2010	BPS
Bireuen	Laki-laki	68.26	2010	BPS
Aceh Utara	Laki-laki	66.34	2010	BPS
Aceh Barat Daya	Laki-laki	61.55	2010	BPS
Gayo Lues	Laki-laki	62.34	2010	BPS
Aceh Tamiang	Laki-laki	66.59	2010	BPS
Nagan Raya	Laki-laki	66.2	2010	BPS
Aceh Jaya	Laki-laki	64.35	2010	BPS
Bener Meriah	Laki-laki	66.53	2010	BPS
Pidie Jaya	Laki-laki	67.02	2010	BPS
Kota Banda Aceh	Laki-laki	68.69	2010	BPS
Kota Sabang	Laki-laki	67.52	2010	BPS
Kota Langsa	Laki-laki	66.66	2010	BPS
Kota Lhokseumawe	Laki-laki	68.51	2010	BPS
Kota Subulussalam	Laki-laki	60.72	2010	BPS
Sumatera Utara	Laki-laki	65.59	2010	BPS

Ketiga sumber dataset diintegrasikan menjadi satu file CSV yang berisi informasi Kabupaten_Provinsi, Jenis Kelamin, Nilai, Tahun, dan Sumber.

- Data Cleaning

kabupaten_provinsi	jenis_kelamin	nilai	sumber
Aceh	Laki-laki	67.17	BPS
Simeulue	Laki-laki	62.15	BPS
Aceh Singkil	Laki-laki	64.76	BPS
Aceh Selatan	Laki-laki	61.04	BPS
Aceh Tenggara	Laki-laki	64.9	BPS
Aceh Timur	Laki-laki	65.95	BPS
Aceh Tengah	Laki-laki	66.24	BPS
Aceh Barat	Laki-laki	65.2	BPS
Aceh Besar	Laki-laki	67.34	BPS
Pidie	Laki-laki	64.2	BPS
Bireuen	Laki-laki	68.26	BPS
Aceh Utara	Laki-laki	66.34	BPS
Aceh Barat Daya	Laki-laki	61.55	BPS
Gayo Lues	Laki-laki	62.34	BPS
Aceh Tamiang	Laki-laki	66.59	BPS
Nagan Raya	Laki-laki	66.2	BPS
Aceh Jaya	Laki-laki	64.35	BPS
Bener Meriah	Laki-laki	66.53	BPS
Pidie Jaya	Laki-laki	67.02	BPS
Kota Banda Aceh	Laki-laki	68.69	BPS
Kota Sabang	Laki-laki	67.52	BPS
Kota Langsa	Laki-laki	66.66	BPS
Kota Lhokseumawe	Laki-laki	68.51	BPS
Kota Subulussalam	Laki-laki	60.72	BPS
Sumatera Utara	Laki-laki	65.59	BPS

Dataset gabungan dilakukan cleaning yang disimpan dalam file CSV yang berisi informasi Kabupaten_Provinsi, Jenis_Kelamin, Nilai, dan Sumber.

- Data Explorasi (EDA)
Hasil EDA disimpan dalam satu folder yang di dalamnya berisi beberapa file dengan format .png. Berikut isi folder yang terbentuk:



boxplot_ahh_gender.png



gap_ahh_gender.png



heatmap_ahh_provinsi_tahun.png



rata_rata_ahh_gender.png



tren_ahh_gender.png



tren_ahh_nasional.png



tren_ahh_top5_laki_laki.png




tren_ahh_top5_perempuan.png



tren_ahh_top5_provinsi.png

2.6.3 Dokumentasi Pipeline



Dari Flow pengerjaan diatas dapat dijabarkan sebagai berikut:

- Mengunduh dataset dari tiga sumber yang berbeda. Dataset diunduh secara manual dengan format CSV yang selanjutnya semua dataset dimasukkan ke dalam folder Google Drive agar bisa dihubungkan dengan google colab.
- Dataset yang berhasil terbaca oleh google colab dilakukan cleaning per dataset lalu dilanjut dengan mengintegrasikan seluruh dataset yang sudah melalui proses cleaning. Hasil integrasi seluruh dataset di simpan dalam folder output dengan format file CSV.
- File CSV hasil integrasi dilakukan cleaning untuk menghapus duplikasi, kolom tidak relevan, standarisasi nama kolom, Konversi tipe data, handling missing value, dan preprocessing (Normalisasi kolom kunci, menghitung tren AHH, interpolasi tahun, dan agregasi provinsi, tahun, dan gender) .
- Proses cleaning menghasilkan beberapa file preprocessing untuk persiapan melakukan EDA. Dari file tersebut akan tercipta EDA untuk mengetahui tren AHH di indonesia, Membandingkan AHH laki-laki dan perempuan, Menganalisis faktor yang memengaruhi AHH laki-laki vs Perempuan, Mengidentifikasi pola khusus per wilayah, dan mengetahui Tren AHH 5 Provinsi Tertinggi.
- Tujuan dari project sudah tercapai di proses EDA, namun dari dataset yang sudah diolah dapat dilanjutkan untuk membentuk analisis lanjutan seperti menghitung statistik berdasarkan tahun, wilayah, dan jenis kelamin.
- Langkah terakhir adalah mengupload dokumentasi project ini ke github.

BAB III

KESIMPULAN

Dalam project ini, kami berhasil mengintegrasikan tiga sumber data berbeda yaitu BPS, Open Data Jawa Barat, dan Open Data Aceh sehingga menjadi satu dataset komprehensif yang berisi informasi Angka Harapan Hidup (AHH) berdasarkan kabupaten/kota, tahun, dan jenis kelamin. Seluruh dataset melewati proses cleaning yang mencakup standarisasi nama kolom, konversi tipe data, penanganan missing value, penghapusan duplikasi, dan normalisasi kolom tahun sehingga data siap digunakan untuk analisis lebih lanjut. Proses preprocessing kemudian menghasilkan panel data yang lengkap serta agregasi yang memungkinkan analisis tren AHH secara nasional maupun per wilayah.

Berdasarkan hasil Exploratory Data Analysis (EDA), terlihat bahwa tren AHH Indonesia dari 2010 hingga 2024 menunjukkan peningkatan yang stabil, menggambarkan perbaikan kualitas kesehatan masyarakat. Analisis perbandingan gender menunjukkan bahwa AHH perempuan secara konsisten lebih tinggi dibanding laki-laki dengan selisih sekitar 3,7–4 tahun, menunjukkan adanya perbedaan biologis maupun faktor risiko yang berbeda antar gender. Visualisasi heatmap memperlihatkan variasi AHH antarwilayah, di mana daerah perkotaan dan ekonomi maju cenderung memiliki nilai lebih tinggi dibanding daerah dengan keterbatasan akses, sehingga mengindikasikan adanya ketimpangan pembangunan kesehatan antarwilayah. Analisis tren lima wilayah dengan AHH tertinggi juga memperlihatkan peningkatan jangka panjang yang konsisten pada setiap gender.

Dengan demikian, seluruh tujuan project telah tercapai, mulai dari memahami tren AHH nasional, membandingkan nilai berdasarkan gender, mengidentifikasi faktor-faktor yang memengaruhi perbedaan AHH, hingga menemukan pola khusus per wilayah. Dataset yang telah dibersihkan dan diproses juga siap digunakan untuk analisis lanjutan atau pemodelan di masa depan. Project ini diharapkan dapat menjadi dasar dalam pengambilan kebijakan kesehatan yang lebih tepat sasaran serta mendukung pemerataan kualitas hidup masyarakat Indonesia.